

A large passenger ship, the Titanic, is shown sailing on the ocean under a clear blue sky. The ship has a white hull with a red stripe along the bottom and two prominent orange funnels with black tops. The ship is viewed from a side-on perspective, moving towards the right.

DATA SCIENCE REPORT

Features Engineering & ML sul Dataset Titanic

Alisia Sallemi & Gianluca Cerea

Analisi predittiva della sopravvivenza dei passeggeri tramite modelli avanzati di machine learning e ottimizzazione degli iperparametri.

Kaggle Competition: [Titanic - Machine Learning from Disaster](#)

Data di pubblicazione: 10 Giugno 2026

Introduzione e Obiettivi del Progetto




Overview

891

PASSEGGERI TRAINING

418

PASSEGGERI TEST



<https://www.kaggle.com/competitions/titanic>
https://github.com/gianluca00/progetto_titanic



Problema di ML

Il task è un problema di **classificazione binaria supervisionata** volto a predire la sopravvivenza dei passeggeri.

$$y = f(X) \mid y \in \{0, 1\}$$

Ingegneria delle Caratteristiche

Trasformazione dei dati grezzi in feature informative per il modello.

Ottimizzazione Modelli

Confronto di algoritmi e fine-tuning degli iperparametri tramite CV.

Generalizzazione


Massimizzare la capacità predittiva su dati mai visti (Test Set).

Descrizione del Dataset e Variabili


VARIABILE	TIPO	CATEGORIA	DESCRIZIONE	NOTE
Survived	Integer	Target Binario	Esito della sopravvivenza	0 = No, 1 = Sì
Pclass	Ordinal	Socio-economica	Classe del biglietto	1ª, 2ª o 3ª classe
Sex	Categorical	Demografica	Sesso biologico	male / female
Age	Float	Numerica	Età in anni	177 valori mancanti
SibSp	Integer	Relazionale	Fratelli, sorelle o coniugi a bordo	Range: 0–8
Parch	Integer	Relazionale	Genitori o figli a bordo	Range: 0–6
Fare	Float	Numerica	Tariffa del biglietto (£)	Distribuzione asimmetrica
Embarked	Categorical	Logistica	Porto di imbarco	C, Q, S
Name	String	Testuale	Nome e titoli nobiliari	Usato per Feature Engineering
Cabin	String	Incompleta	Numero della cabina	77.1% valori mancanti
Ticket	String	Non Inf.	Codice alfanumerico biglietto	Rimosso dall'analisi
PassengerId	Integer	ID	Identificatore univoco	Rimosso (non predittivo)

Analisi Esplorativa dei Dati (EDA)

Distribuzione Variabile Target (Survived)



Tasso di Sopravvivenza per Genere



Sbilanciamento: Dataset moderatamente sbilanciato (62% vs 38%).



Gender Gap: Le donne avevano una probabilità di sopravvivenza ~4x superiore.



Classe: Maggioranza in 3a classe (55%), correlata a tariffe minori.

Distribuzioni Numeriche e Correlazioni

FEATURE	PCLASS	AGE	SIBSP	PARCH	FARE
PCLASS	1.00	-0.37	0.08	0.02	-0.55
AGE	-0.37	1.00	-0.31	-0.19	0.10
SIBSP	0.08	-0.31	1.00	0.41	0.16
PARCH	0.02	-0.19	0.41	1.00	0.22
FARE	-0.55	0.10	0.16	0.22	1.00

COEFFICIENTE DI PEARSON (R)

$$r(X,Y) = \Sigma[(X_i - \bar{X})(Y_i - \bar{Y})] / [n \cdot \sigma_x \cdot \sigma_y]$$

-0.55

Correlazione Pclass ↔ Fare

La relazione lineare più significativa evidenzia come lo status socio-economico (Pclass) sia inversamente proporzionale alla tariffa pagata.

 Age: Distr. Normale

 Fare: Forte Skewness (+)

Gestione dei Valori Mancanti

Analisi Quantitativa (N=891)

Variabile	N. Mancanti	Percentuale
Cabin	687	77.1%
Age	177	19.9%
Embarked	2	0.22%

Totale valori mancanti rilevati nel dataset: 689

Variabile: Cabin

DROP COLUMN

Data la percentuale critica di dati mancanti (77.1%), qualsiasi imputazione introdurrebbe **rumore statistico** eccessivo. La variabile viene rimossa per garantire la stabilità del modello.

Variabile: Age

IMPUTATION

I valori mancanti (19.9%) sono gestiti tramite **imputazione con la mediana**. Questa strategia preserva la distribuzione centrale ed evita distorsioni causate da outlier estremi.

Variabile: Embarked

REMOVAL

Nonostante i soli 2 NA, la variabile è stata rimossa insieme a *Ticket* e *PassengerId* poiché considerata **poco informativa** ai fini della classificazione predittiva finale.

Feature Engineering: FamilySize e Fare Log



Integrazione Nucleo Familiare

$$\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$$

Motivazione: Le variabili **SibSp** (fratelli/coniugi) e **Parch** (genitori/figli) singolarmente non catturano l'unità familiare completa.

Pattern di Sopravvivenza: I nuclei di 2-4 persone hanno mostrato tassi di sopravvivenza superiori rispetto a viaggiatori solitari o famiglie numerose.

Semplificazione: Riduce la dimensionalità combinando due variabili correlate ($r=0.41$) in un unico indicatore sociale.

Il "+1" include il passeggero stesso nel conteggio del nucleo.



Trasformazione Logaritmica

$$\text{Fare_log} = \log(\text{Fare} + 1)$$

Problema Originale: La variabile **Fare** presenta una distribuzione fortemente asimmetrica a destra (skewness positiva).

Gestione Outlier: La trasformazione riduce l'impatto dei valori estremi (fino a £512) che potrebbero distorcere i modelli lineari.

Normalizzazione: Avvicina la distribuzione a una forma normale, migliorando la stabilità di convergenza per Logistic Regression e SVM.

L'aggiunta di "+1" evita l'indefinitezza del logaritmo per tariffe pari a zero.

Feature Engineering: Titoli e Normalizzazione

Estrazione dei Titoli (Regex)

Il campo *Name* contiene titoli che fungono da proxy per genere, età e status sociale.

Mr	Uomini adulti	577
Miss	Donne nubili e bambine	182
Mrs	Donne sposate	125
Master	Bambini maschi	40
Rare	Dr, Rev, Nobiltà, Militari	22

Normalizzazione Min-Max

- ✓ Modelli lineari (Reg. Logistica, SVM) sono sensibili alla scala delle variabili.

$$\text{Age_norm} = (\text{Age} - \text{min}) / (\text{max} - \text{min})$$


- ✓ Riconduce la variabile **Age** in un intervallo fisso [0, 1] preservando i rapporti originali.
- ✓ Previene che variabili con range elevati dominino la funzione di costo.

Range Originale [0.42, 80] → Range Normalizzato [0.0, 1.0]

Riduzione della Dimensionalità con PCA

Fondamenti Teorici

La **Principal Component Analysis (PCA)** è una tecnica di apprendimento non supervisionato che proietta i dati originali in un nuovo spazio di caratteristiche ortogonali, massimizzando la varianza spiegata in ogni componente.



L'obiettivo primario è ridurre il numero di variabili mantenendo la maggior parte dell'informazione originale (varianza).

Applicazione sul Dataset Titanic

- ✓ **Gestione Multicollinearità:** Risolve la forte correlazione lineare tra variabili come *Pclass* e *Fare*.
- ✓ **Riduzione del Rumore:** Filtra le fluttuazioni non informative derivanti dalle feature ingegnerizzate.
- ♥ **Generalizzazione:** Migliora la robustezza dei modelli lineari riducendo il rischio di overfitting.
- 🏠 **Componenti Ortogonali:** Le nuove feature sono indipendenti, ottimizzando il training della Regressione Logistica.

NOTA METODOLOGICA

Tutti i modelli nel report utilizzano `use_pca: true` per garantire uniformità comparativa.

Panoramica dei Modelli di Machine Learning



Regressione Logistica

Modello lineare fondamentale per la classificazione binaria. Estremamente interpretabile, calcola la probabilità che un passeggero appartenga alla classe dei superstiti.

- Efficace per dati linearmente separabili.
- Regularizzazione L2 per prevenire overfitting.

$$P(y=1|x) = 1 / (1 + e^{(-w^T x)})$$



Support Vector Classifier (SVC)

Algoritmo basato sulla ricerca dell'iperpiano di separazione a margine massimo tra le classi Survived=0 e Survived=1.

- Kernel RBF per gestire relazioni non lineari.
- Sensibile alla scala: richiede normalizzazione Age.
- Parametro C controlla il trade-off del margine.



Random Forest

Metodo ensemble di tipo Bagging che aggrega multipli alberi decisionali addestrati su subset casuali di dati e feature.

- Riduce la varianza rispetto al singolo albero.
- Predizione finale tramite voto a maggioranza.
- Robusto contro outlier e valori mancanti.



XGBoost

Implementazione avanzata di Gradient Boosting. Addestra alberi in sequenza, dove ogni nuovo albero corregge gli errori dei precedenti.

- Ottimizzato per velocità e performance.
- Gestisce nativamente la regularizzazione.
- Apprendimento iterativo tramite gradient descent.

Analisi delle Metriche e Risultati Baseline

MODELLO (PCA BASELINE)	ACCURACY TRAIN	ACCURACY TEST	F1 SCORE TRAIN	F1 SCORE TEST
Logistic Regression Modello Lineare	0.7874	0.8026	0.7873	0.8030
SVC (Kernel RBF) Support Vector Machine	0.8188	0.7960	0.8174	0.7940
XGBoost Gradient Boosting	0.8220	0.7763	0.8116	0.7535
Random Forest Ensemble (Bootstrap)	0.9176	0.7697	0.9167	0.7666

BEST BASELINE Regressione Logistica

Il modello più solido nel test set (Acc: 0.8026). Mostra un'ottima generalizzazione con metriche train/test quasi identiche, confermando la linearità di molti pattern principali.

OVERFITTING CRITICO Random Forest

Forte discrepanza tra Train (0.917) e Test (0.769). Il modello ha memorizzato il rumore del dataset. Necessita di una drastica riduzione della complessità tramite fine-tuning.

Strategie di Fine-Tuning



Random Search (Random Forest)

Ottimizzazione stocastica su 10 iterazioni per identificare rapidamente le regioni promettenti dello spazio dei parametri.

N_ESTIMATORS

[50, 100, 200]

MAX_DEPTH

[3, 5, 7]

Migliori Parametri

max_depth: 7, n_estimators: 200
Riduzione efficace dell'overfitting rispetto al baseline.



Grid Search (Logistic Regression)

Esplorazione esaustiva di 30 combinazioni per ottimizzare la regolarizzazione e la convergenza del modello lineare.

C (REGULARIZATION)

[0.01, 0.1, 1, 10, 100]

CLASS_WEIGHT

"balanced"

Migliori Parametri

C: 10, solver: "lbfgs", penalty: "l2"
Ottimizzazione della gestione dello sbilanciamento delle classi.

Metodologia: 5-Fold Cross-Validation

Il dataset viene diviso in 5 partizioni (fold). Il modello viene addestrato 5 volte, usando ogni volta un fold diverso per la validazione, garantendo una stima robusta della performance.

VAL

TRAIN

TRAIN

TRAIN

TRAIN


- **Metriche Ottimizzate**

Accuracy (CV)

F1 Score

Impatto del Tuning sulle Performance

Confronto Accuratezza Test: Baseline vs Fine-tuned



Modello	Baseline	Fine-tuned	Δ
Random Forest	0.7697	0.8208	+0.0511
Logistic Regression	0.8026	0.8010	-0.0016

Key Takeaways

Il **Random Forest** beneficia maggiormente del tuning (+5.1%), risolvendo i critici problemi di overfitting riscontrati nella baseline.

La **Logistic Regression** si conferma estremamente robusta già in configurazione standard, con variazioni minime post-ottimizzazione.

Sviluppi Futuri e Ottimizzazioni

L'evoluzione del progetto mira a consolidare la robustezza predittiva attraverso l'integrazione di tecniche avanzate di ensemble e metodi di interpretazione dei modelli.



Ensemble Stacking

Combinazione di LogReg, RF e SVC come base learners e XGBoost come meta-learner per catturare pattern complementari e ridurre il bias sistematico.



Oversampling SMOTE

Applicazione della Synthetic Minority Oversampling Technique per bilanciare le classi (62%/38%), migliorando la Recall sui sopravvissuti.



Interpretability SHAP

Analisi dei valori SHAP per quantificare l'impatto marginale di ogni feature sulla probabilità di sopravvivenza, garantendo trasparenza decisionale.

#FeatureEngineering_IsAlone

#DeckExtraction

#LightGBM_Testing

#StratifiedKFold_10

Conclusioni e Sintesi Finale

💡 Lezioni Apprese e Takeaways

- ▢ **Feature Engineering come Driver:** La creazione di variabili come *FamilySize* e l'estrazione dei *Titoli* si è rivelata più determinante della scelta dell'algoritmo stesso.
- ▢ **Efficacia del Fine-Tuning:** L'ottimizzazione degli iperparametri (Random Search) ha permesso di recuperare oltre 5 punti percentuali di accuracy sul Random Forest.
- ▢ **Robustezza dei Modelli Lineari:** La Regressione Logistica ha confermato la sua validità come baseline solida, superando modelli complessi in termini di generalizzazione iniziale.
- ▢ **Trasformazione dei Dati:** La gestione dell'asimmetria (Log-Fare) e la normalizzazione (Age) sono passaggi critici per garantire la convergenza dei modelli basati su gradiente.

BEST ACCURACY

82.08%

Raggiunta con Random Forest post-tuning

MIGLIORAMENTO TUNING

+5.1%

Incremento performance vs baseline

MODELLO PIÙ STABILE

LogReg

Miglior bilanciamento Train vs Test



Il progetto dimostra che un approccio rigoroso al **Preprocessing** e al **Feature Engineering** è la chiave per sviluppare modelli di Machine Learning robusti, interpretabili e capaci di generalizzare su dati non visti.